

利用多源光谱信息反演宁夏银北地区干湿季土壤含盐量

贾萍萍, 尚天浩, 张俊华*, 孙 媛

(1. 宁夏大学资源环境学院, 银川 750021; 2. 宁夏大学环境工程研究院, 银川 750021;
3. 宁夏旱区资源评价与环境调控重点实验室, 银川 750021)

摘要: 土壤盐渍化是导致全球荒漠化和土壤退化的主要诱因之一。为确定高光谱和多光谱遥感反演干湿季土壤含盐量的最优模型, 该研究以宁夏银北平罗县为例, 以干季(4月)和湿季(10月)实测高光谱和 Landsat 8 OLI 多光谱以及干湿两季实测土壤含盐量为基础数据源, 利用相关系数法、灰度关联法和逐步回归法筛选敏感光谱数据, 分别采用偏最小二乘、支持向量机、岭回归、BP 神经网络和地理加权回归建立干湿两季土壤含盐量反演模型。结果表明: 1) 银北地区土壤盐渍化较为严重, 干湿季含盐量均表现为强度变异, 且干季变异程度大于湿季; 2) 在不同土壤含盐量条件下, 重采样后的高光谱波段反射率和影像波段反射率具有显著相关性; 3) 对比相关性分析、灰度关联和逐步回归三组变量筛选方法下各模型 R^2 和 RMSE, 逐步回归组模型整体效果较好; 4) 5 种土壤含盐量反演模型中地理加权回归模型精度较高, 支持向量机算法和 BP 神经网络算法在基于不同变量组的模型中表现较为接近, 岭回归表现最差, 偏最小二乘回归模型出现了较严重的“过拟合”现象。局部模型在土壤含盐量反演方面更具优越性。干季以实测灰度关联组-地理加权回归模型效果最佳, 其验证决定系数 R_p^2 和相对分析误差 RPD 分别为 0.94 和 4.49; 湿季以影像相关系数组-地理加权回归模型反演效果最好, 其验证决定系数 R_p^2 和相对分析误差 RPD 分别为 0.96 和 4.83。研究结果可为当地及同类地区土壤盐渍化的识别、防治提供理论依据。

关键词: 遥感; 反演; 模型; 土壤含盐量; 光谱指数; GWR 模型

doi: 10.11975/j.issn.1002-6819.2020.17.015

中图分类号: S127; TP79

文献标志码: A

文章编号: 1002-6819(2020)-17-0125-10

贾萍萍, 尚天浩, 张俊华, 等. 利用多源光谱信息反演宁夏银北地区干湿季土壤含盐量[J]. 农业工程学报, 2020, 36(17): 125-134. doi: 10.11975/j.issn.1002-6819.2020.17.015 <http://www.tcsae.org>

Jia Pingping, Shang Tianhao, Zhang Junhua, et al. Inversion of soil salinity in dry and wet seasons based on multi-source spectral data in Yinbei area of Ningxia, China[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(17): 125-134. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.2020.17.015 <http://www.tcsae.org>

0 引言

土壤盐渍化是关系到干旱地区可持续发展的战略性问题, 受到世界各国的广泛关注^[1], 据统计, 盐渍土占全球整个陆地面积的 7.26%, 严重影响着当地生态、经济的可持续发展^[2]。中国是受盐渍化影响最严重的国家之一, 其西北干旱和半干旱地区土壤盐渍化问题尤为突出^[3]。盐渍土作为重要的后备耕地资源, 对其进行准确监测、开发利用已迫在眉睫^[4]。

农业生产中, 土壤盐渍化的监测对农作物管理具有十分重要的指导作用^[5]。传统的土壤含盐量测定费时、费力、成本高且无法全面获取数据。近年来, 随着光谱分析技术的发展, 遥感技术已成为大面积监测和评估土壤盐渍化的主要手段^[6]。但由于土壤盐渍化产生原因及土壤盐分组成复杂, 在土壤盐分遥感监测敏感波段和盐分指

数的选择上, 不同区域的研究结果存在差异^[7-8]。所以, 定量分析光谱数据时特征变量的选取就显得非常重要。目前, 常用的变量优选方法主要有相关性分析 (Pearson Correlation Coefficient, PCC)^[9]、灰度关联 (Gray Correlation, GC)^[10]、逐步回归 (Stepwise Regression, SR)^[10]、变量投影重要性分析 (Variable Importance in Projection, VIP)^[10]等。王海峰^[10]采用 GC、SR 和 VIP 三种波段分析法并使用偏最小二乘回归 (Partial Least Squares Regression, PLSR) 和支持向量机回归 (Support Vector Machine, SVM) 对不同盐离子进行了反演, 不同波段分析方法下各模型精度不同。Wang 等^[9]基于 PCC、VIP、GC、随机森林 (Random Forest, RF) 筛选敏感因子, 并分别利用 PLSR 建立了含盐量反演模型, 结果表明 RF-PLSR 效果最佳, 其 R^2 达到 0.93。不同建模方法反演效果也不同, 张俊华等^[11]发现利用 PLSR 建立光谱数据模型对 SO_4^{2-} 、 Ca^{2+} 、 Na^+ 都有较高的反演精度, 但冯娟等^[12]指出采用 SVM 模型较 PLSR 模型对含盐量的反演精度更高, 而刘恩等^[13]以 Landsat 8 OLI 多光谱影像数据建立的土壤含盐量反演模型中, BP 神经网络 (Back Propagation Neural Networks, BPNN) 模型预测精度也显示出一定的优越性, 其 R^2 达到 0.980 8。此外, 岭回归 (Ridge Regression, RR) 作为一种新的光谱定量分析方法, 在

收稿日期: 2020-05-14 修订日期: 2020-06-27

基金项目: 国家自然科学基金项目 (41561078); 宁夏自然科学基金项目 (2020AAC03113)

作者简介: 贾萍萍, 主要从事荒漠化与水土保持的研究

Email: 1606425266@qq.com

*通信作者: 张俊华, 博士, 研究员, 博士生导师, 主要从事精准农业与土壤质量提升研究。Email: zhangjunhua728@163.com

土壤含水率、叶绿素浓度等反演方面已显示出较好的效果^[14-15]。以上提到的反演模型均属于全局性模型,它们将自变量与因变量的关系视为全局不变,而忽略了两者的空间变异性所导致的关系变化^[16]。Petlo 等^[17]在 1968 年首次将局部回归的思想用于处理非等间隔分布的高程数据,并获得满意的结果。Fotheringham 等^[18]提出了地理加权回归 (Geographically Weighted Regression, GWR), 将自变量与因变量之间的非稳态关系引入到模型中,使得反演更加准确有效,但 RR 和 GWR 模型目前在土壤含盐量方面的应用还较少^[10, 16]。

土壤盐渍化程度常伴随季节和空间的变化而变化,不同季节、不同地点土壤光谱与含盐量信息之间的关系参差不齐,土壤盐分时空维度差异较大^[19],所以 GWR 在盐分反演中的表现值得研究。另外,虽然很多基于不同平台的遥感数据源建立的土壤盐分反演模型取得了较理想的精度,但这些研究多是依据某一特定时期开展的,仅能反映单一时期的土壤盐分信息^[20-21]。在前期研究中^[22],课题组利用线性和非线性函数对高光谱重采样波段和影像盐分指数进行筛选,进而对干湿两季的总含盐量进行了估算,发现利用遥感数据可以达到准确反演不同季节含盐量的目的,但光谱筛选方法较为单一,且建模过程中未考虑回归参数与样点地理位置的关系,所以,本文在其基础上,以实地采样点的土壤高光谱反射率以及研究区 Landsat 8 OLI 多光谱遥感影像为数据源,使用 PCC、GC 和 SR 三种方法筛选敏感光谱数据,然后采用 PLSR、SVM、RR、BPNN 和 GWR 五种方法分别对实测和影像数据下的干季和湿季 0~20 cm 的含盐量进行反演,评定不同模型输入变量和不同建模方法下含盐量反演模型的精度,综合评价各模型对土壤含盐量的反演效果,以期得到不同季节最佳的光谱反演模型,为当地及同类地区土壤盐渍化的识别、防治和制定相关利用措施提供理论依据。

1 材料与方法

1.1 研究区概况

研究区位于宁夏银北地区石嘴山市平罗县 (38°26'60"~39°14'09"N, 105°57'40"~106°52'52"E), 地处贺兰山东麓洪积扇与平原之间,面积 2 060 km²,该地区属干旱-暖温带季风气候,年平均温度 9℃,降水量稀少 (平均 150~203 mm,主要集中在 6—10 月),蒸发强烈 (>1825 mm)。由于地质环境、地形、农业不合理灌溉等影响,导致本地盐渍化现象普遍。研究区主要土壤类型为灰钙土、盐土、碱土和灌淤土,土壤母质多为碳酸盐型母质,主要土地利用和土地覆盖类型包括基本农田、水体、撂荒地和盐碱地等。天然植被多为盐生植物,如白刺、芦苇、碱蓬等,植被覆盖度低,有利于通过遥感影像反演土壤含盐量。

1.2 野外高光谱数据和样品采集与处理

样点布局充分考虑研究区土壤表面盐分特征和土地利用方式等因素,在全县共设置 9 个采样区域,包括基本农田、中低产田和撂荒地等不同程度的盐渍化土地 (图 1),采样时间为 2018 年 10 月 24—25 日 (湿季) 和 2019 年 4

月 18—19 日 (干季)。每个样区实地进行土壤光谱测定 (样点间隔为 30、60、100、200、300 m 不等)。野外土壤光谱采用美国 SR-3500 地物光谱仪测定土壤光谱反射率,波段范围为 350~2 500 nm。光谱测定时间在 10:00—14:00,天气状况良好,每次测定前先进行标准白板校正,探头设置在垂直距离土表 80 cm (与测量人腰部同高) 处,每个样点重复测定 5 次,求平均值作为该样点的光谱反射值。光谱采集后在该点原处用土钻采集土壤样品 (0~20 cm, 非混合土样),其中 10 月份采集样本共 57 个,4 月份 59 个,土样装入密封袋,采用手持 GPS 记录各样点经纬度,并同时记录周围地表类型和植被盖度等信息。利用烘干法测定土壤含水率,电导法测定土壤 EC,然后转换为土壤含盐量,参考王遵亲等^[23]土壤盐渍化分级方法,将采样点的土壤分为非盐渍化、轻度盐渍化、中度盐渍化、重度盐渍化和盐土,其中非盐渍土、轻度盐渍土、中度盐渍土、重度盐渍土和盐土占比分别为 5%、40%、7.5%、25%、22.5%。

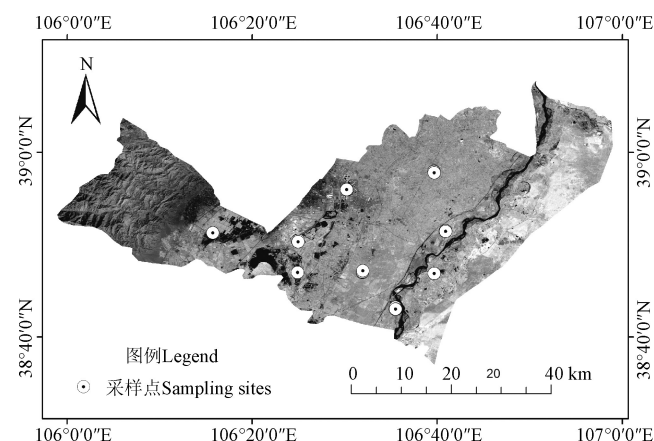


图 1 研究区位置与采样点分布

Fig.1 Location of study area and distribution of the sampling sites

在 ENVI5.2.2 软件中运用波谱重采样工具,通过影像传感器波谱响应函数将光谱仪 350~2 500 nm 波段光谱进行重采样,使其与 Landsat 8 OLI 影像光谱波段相匹配。

1.3 卫星数据与预处理

根据采样时间,文中使用的影像数为覆盖研究区 2018 年 10 月 27 日和 2019 年 4 月 21 日的 Landsat 8 OLI 遥感影像 (美国地质调查局 (http://glovis.usgs.gov/) 官网下载),其行列号为 129/33。为减少大气对影像精度的影响,且更好的拟合影像数据与土壤含盐量数据,在 ENVI 5.5.2 中对影像进行辐射和大气校正,将辐射率转化为地表反射率,进而提取各采样点在 9 个波段的反射率,并利用 Band math 模块计算盐分指数。

Landsat 8 OLI 数据有 9 个波段 (海岸波段 Coastal: 433~453 nm、蓝波段 Blue: 450~515 nm、绿波段 Green: 525~600 nm、红波段 Red: 630~680 nm、近红外波段 NIR: 845~885 nm、短波红外 1 SWIR1: 1 560~1 651 nm、短波红外 2 SWIR2: 2 100~2 300 nm、全色波段 Pan 500~680、卷云波段 Cirrus: 1 360~1 390nm),空间分辨率为 30 m,全色波段分辨率为 15 m。选取除海岸波段和全波段以外的波段参与研究。

1.4 盐分指数

盐分指数是不同波段的数学组合，可用于建立光谱数据与特定目标之间的相关性，并为土壤含盐量研究提供了科学依据^[24]。本文选取了常用的 11 种盐分指数与土壤含盐量进行定量分析，光谱波段为重采样后的实测数据和预处理后的影像数据，计算公式见表 1。

表 1 盐分指数
Table 1 Salinity indices

盐分指数 Salinity indices	公式 Formulas	盐分指数 Salinity indices	公式 Formulas
SI-T ^[25]	$\frac{R}{NIR} \times 100$	S1 ^[28]	B/R
SI ^[25]	\sqrt{BR}	S2 ^[28]	$\frac{B-R}{B+R}$
NDSI ^[26]	$\frac{R-NIR}{R+NIR}$	S3 ^[28]	$\frac{GR}{B}$
SI1 ^[27]	\sqrt{GR}	Int1 ^[29]	$\frac{G+R}{2}$
SI2 ^[27]	$\sqrt{G^2+R^2+NIR^2}$	Int2 ^[29]	$\frac{G+R+NIR}{2}$
SI3 ^[27]	$\sqrt{G^2+R^2}$		

注：R 为红色分量值，G 为绿色分量值，B 为蓝色分量值，NIR 为近红外分量值。

Note: R is red band component value; G is green band component value; B is blue band component value; NIR is near infrared band component value.

1.5 特征光谱筛选

选用 PCC、GC 和 SR 进行特征光谱参量筛选。PCC 中相关系数绝对值越大，说明该数据的光谱信息量越多，通常 PCC 有助于揭示土壤盐分含量与可见—近红外光谱之间的关系，并在一定程度上预示了建模效果^[30]。GC 是通过关联度的计算与比较来辨别系统中各因素间的主次关系，关联度越大，相似程度越高，由于灰色关联度的大小会受到样本数量的影响^[31]，故从干季中随机去掉 2 个样本来计算灰色关联度，使干湿季土壤光谱指标计算出的灰色关联度有可比性；为消除量纲的影响，对数据做“均值化”预处理。SR 是根据自变量对因变量的显著

程度，由大到小地逐个引入回归方程，剔除对因变量作用不显著的自变量，建立最优回归方程^[10]。

1.6 模型建立及评价指标

通过 K-S 算法^[32]选用 2/3 的样本用于建模（干季 39，湿季 38），1/3 的样本用于验证（干季 20，湿季 19）。分别基于干湿季土壤样本建立含盐量反演模型，选用 PLSR、RR、SVM、BPNN 和 GWR 进行建模^[33-37]。其中，PLSR 建模过程中利用完全交叉验证法来选取最佳主成分个数^[33]；RR 过程中利用岭迹法判断岭参数 k 的取值^[34]；SVM 中核函数类型使用 Radial basis function，使用训练集交叉验证和网格搜索法（Grid search）进行参数寻优，按照均方差最小原则确定惩罚参数 C 和核参量 g 的值^[35]；BPNN 中，数据转换方式为标准化转换，隐含层节点数按经验选取输入层节点数的 75%，最小训练速率取 0.1，迭代次数取 1 000 次，多次训练后取拟合残差最小时结果为模型结果^[36]。GWR 中使用自适应二次形式的带宽并以常用的 Golden section search 方法来选择，用 AICc 准则来确定。PLSR 和 SVM 在 The UnscramblerX10.4 中进行，RR 和 BPNN 在 DPS 9.01 中进行，GWR 在 GWR4.0 中进行。

模型精度通过建模决定系数 R_c^2 ，验证决定系数 R_p^2 、均方根误差 RMSE 和相对分析误差 RPD 来综合评价。

2 结果与分析

2.1 土壤含水率和含盐量统计分析

由研究区干湿两季土壤含水率和含盐量统计结果可知（表 2），干湿季土壤含水率差异较小，都属于中等程度变异（变异系数 CV 值反映样点值的离散程度，在一定程度上揭示了变量的空间分布特性^[38]， $CV < 0.1$ 为弱变异性； $0.1 < CV < 1$ 为中等变异； $CV > 1$ 为强变异）。干季土壤含盐量平均值大于湿季土壤的平均值。由变异系数知，干季和湿季含盐量均属于强度变异。干湿季整体变异系数大于 1，说明研究区土壤受到不同程度土壤盐渍化影响较强，干季较湿季变异程度大。

表 2 土壤样品的含水率和含盐量统计

Table 2 Statistics of moisture and salt content of the soil samples

特征量 Characteristics	季节 Seasons	采样数 Samples	最小值 Min	最大值 Max	平均值 Mean	标准差 Standard deviation	变异系数 Coefficient of variation
含水率 Moisture content/%	干季	59	0.89	22.12	11.58	0.07	0.61
	湿季	57	6.47	29.43	17.51	0.06	0.34
含盐量 Salt content/(g·kg ⁻¹)	干季	59	0.40	29.33	6.17	8.24	1.34
	湿季	57	0.56	19.08	5.28	5.43	1.03

2.2 土壤实测光谱与影像光谱数据评估

高光谱实现了地物的空间信息、辐射信息和光谱信息的同步获取。分别选取干季和湿季 5 种不同盐渍化程度土壤，对重采样的实测光谱反射率与影像反射率 7 个波段数据进行拟合（图 2），发现二者之间具有良好的拟合度，这可能是由于采样点多多为裸土区，影像光谱为相对较为纯净的像元。干季轻度和中度盐渍化土壤的重采样光谱与影像光谱相关性最强， R^2 达到 0.98，然后是非盐渍化和重度盐渍化， R^2 也达到了 0.97，盐土相关性略

低；湿季重采样光谱与影像光谱相关性轻度和重度盐渍化土壤表现最佳，其次为非盐渍化土壤，而盐土相关性相对较低，但也均达到了极显著水平。因此，经重采样后的高光谱数据与影像反射率具有良好的相关性，可为重采样光谱与影像定量反演含盐量提供较可靠的依据。

2.3 特征光谱筛选结果

2.3.1 相关性分析

土壤含盐量与实测、影像波段及盐分指数之间的相关系数见表 3 和表 4。干季实测数据均通过了显著性检验，

除盐分指数 SI-T 和 NDSI 外, 其余相关性均表现为极显著, 但含盐量与影像波段和盐分指数均未通过显著性检验。湿季土壤含盐量与实测数据相关性均通过了显著性

检验, 含盐量与影像数据的相关性除盐分指数 SI-T、NDSI 和 S3 外均通过了 0.01 显著性检验, 其中与 S1 的相关性最强。选用通过 0.01 显著性的变量为模型因子。

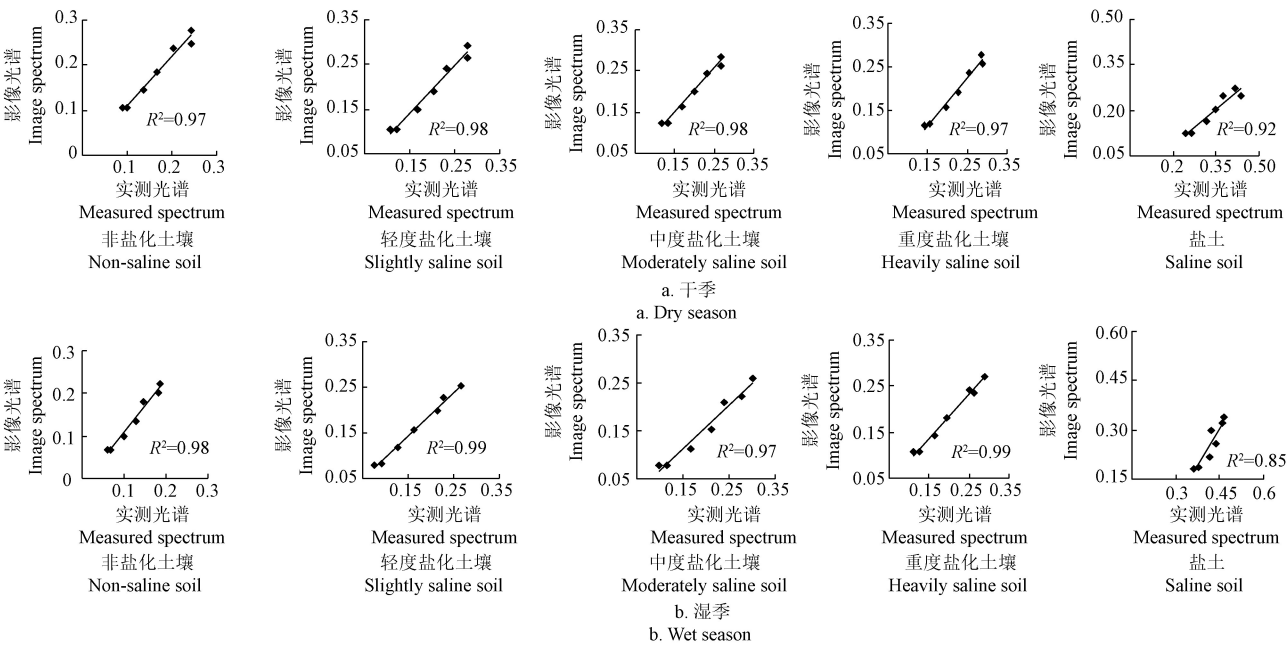


图 2 重采样实测光谱与影像光谱反射率相关性

Fig.2 Correlation between resampling measured spectral reflectance and spectral reflectance of image

表 3 土壤含盐量与实测和影像波段相关性

	实测波段 Measured bands							影像波段 Image bands						
	Band1	Band2	Band3	Band4	Band5	Band6	Band7	Band1	Band2	Band3	Band4	Band5	Band6	Band7
干季	0.79**	0.79**	0.76**	0.71**	0.69**	0.65**	0.69**	0.22	0.15	0.08	0.01	-0.07	-0.25	-0.27
湿季	0.75**	0.74**	0.69**	0.66**	0.65**	0.57**	0.53**	0.63**	0.62**	0.56**	0.53**	0.54**	0.43**	0.43**

注: **表示在 $P<0.01$ 水平显著, *表示在 $P<0.05$ 水平显著。下同

Note: ** means significant at $P<0.01$ levels, * means significant at $P<0.05$ levels. The same below.

表 4 土壤含盐量与实测和影像盐分指数相关性

		土壤含盐量 Soil salt content	
		干季 Dry season	湿季 Wet season
实测盐分指数 Measured salinity indices	SI-T	0.39*	0.49**
	SI	0.76**	0.71**
	NDSI	0.38*	0.46**
	SI1	0.74**	0.68**
	SI2	0.72**	0.67**
	SI3	0.73**	0.68**
	S1	0.61**	0.75**
	S2	0.59**	0.72**
	S3	0.61**	0.57**
影像盐分指数 Image salinity indices	Int1	0.74**	0.68**
	Int2	0.72**	0.67**
	SI-T	0.20	0.33*
	SI	0.08	0.59**
	NDSI	0.20	0.31*
	SI1	0.05	0.55**
	SI2	-0.01	0.55**
	SI3	0.04	0.54**
	S1	0.25	0.66**
	S2	0.25	0.65**
	S3	-0.05	0.37*
	Int1	0.04	0.55**
	Int2	0.00	0.55**

2.3.2 灰度关联法分析

图 3 为干、湿季实测和影像数据与土壤含盐量之间的灰色关联度统计, 其中干季实测数据波段和盐分指数与含盐量灰色关联度均较高, 干季影像数据与含盐量灰色关联度变化整体较为平缓, 湿季影像数据与含盐量灰色关联度整体较小。为实现波段和盐分指数筛选, 本研究设敏感波段和盐分指数的 GCD 阈值为 0.45。

2.3.3 逐步回归分析

基于 SR 分析的干湿季特征光谱数据如表 5 所示, 干湿季实测和影像的最优 SR 模型入选变量的波段和盐分指数个数为 3~9 个。总体来看, SR 模型的调整 R^2 除干季影像外均在 0.60 以上, 说明模型拟合效果较好, 同时所有的显著性均小于 0.001, 表明干湿季 SR 模型均具有显著意义。因此, 选取各 SR 模型入选特征变量作为后续模型的自变量。

2.4 干湿两季土壤含盐量反演模型构建与验证

将经过 PCC、GC 及 SR 筛选后得到的光谱参量作为自变量, 土壤含盐量为因变量, 分别采用 PLSR、SVM、RR、BPNN 和 GWR 法构建干湿季土壤含盐量定量反演模型并进行模型精度验证。干季含盐量反演模型结果如表 6 所示。

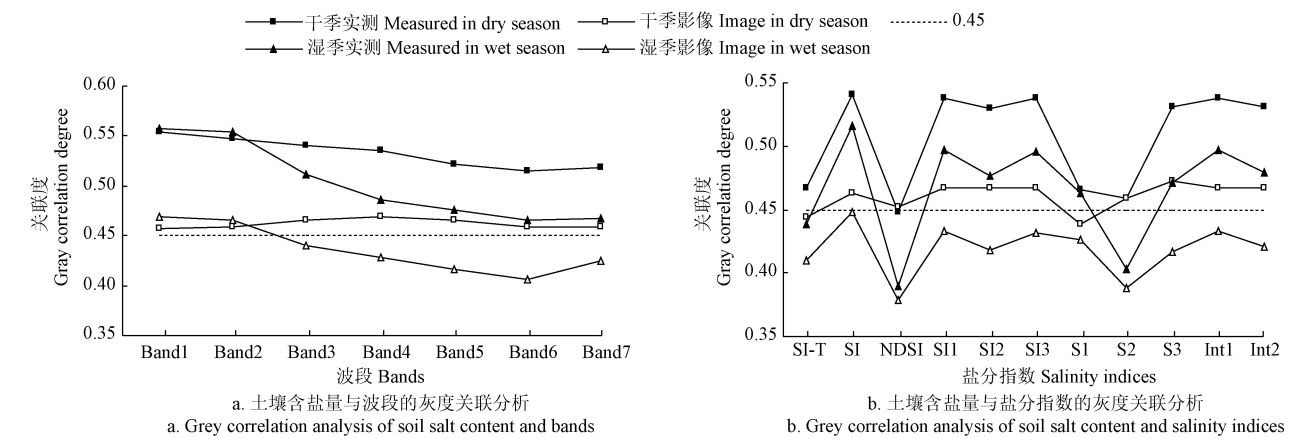


图 3 土壤含盐量与波段和盐分指数的灰度关联分析
Fig.3 Gray correlation analysis of soil salinity and bands and salinity indices

表 5 逐步回归分析筛选特征光谱数据参数指标
Table 5 Parameter index of feature spectral data selection by stepwise regression method

项目 Items	敏感波段 Sensitive bands	敏感盐分指数 Sensitive salinity indices	调整 R^2 Adjust R^2	标准误差 Standard error	显著性 Significance.
干季实测 Measured in dry season	Band3、Band7	S3	0.65	6.29	0.00
干季影像 Image in dry season	Band1、Band2、Band3、 Band6、Band7	SI-T、NDSI、S1、S2	0.48	7.75	0.00
湿季实测 Measured in wet season	—	NDSI、S1、S2、S3、Int2	0.70	3.53	0.00
湿季影像 Image in wet season	Band3、Band6	SI-T、NDSI、S1、S2、S3	0.60	4.11	0.00

表 6 干季土壤含盐量反演模型
Table 6 Modeling of soil salinity in dry season

分析方法 Analytical methods	建模方法 Modeling methods	干季实测 Measured in dry season				干季影像 Image in dry season			
		R_c^2	R_p^2	RMSE/(g·kg ⁻¹)	RPD	R_c^2	R_p^2	RMSE/(g·kg ⁻¹)	RPD
相关性分析 PCC	偏最小二乘 PLSR	0.81	0.13	6.05	1.05	—	—	—	—
	支持向量机 SVM	0.82	0.33	5.94	1.06	—	—	—	—
	岭回归 RR	0.81	0.13	5.60	1.13	—	—	—	—
	BP 神经网络 BPNN	0.83	0.35	5.84	1.11	—	—	—	—
	地理加权回归 GWR	0.89	0.17	5.77	1.10	—	—	—	—
灰度关联法 GC	偏最小二乘 PLSR	0.77	0.08	6.10	1.04	0.02	0.59	8.48	1.56
	支持向量机 SVM	0.82	0.51	5.29	1.20	0.41	0.70	7.72	1.71
	岭回归 RR	0.78	0.29	5.36	1.19	0.14	0.60	8.38	1.58
	BP 神经网络 BPNN	0.89	0.38	3.54	1.83	0.51	0.58	11.57	1.14
	地理加权回归 GWR	0.91	0.94	1.42	4.49	0.51	0.70	7.04	1.88
逐步回归法 SR	偏最小二乘 PLSR	0.80	0.16	6.23	1.02	0.04	0.61	8.31	1.59
	支持向量机 SVM	0.85	0.55	5.18	1.23	0.41	0.71	7.62	1.74
	岭回归 RR	0.78	0.22	5.63	1.13	0.14	0.61	8.33	1.59
	BP 神经网络 BPNN	0.72	0.33	2.50	2.59	0.50	0.59	11.85	1.11
	地理加权回归 GWR	0.86	0.60	1.61	3.94	0.40	0.68	7.03	1.81

注： R_p^2 为验证决定系数，RPD 为相对分析误差。下同。
Note: R_p^2 , validation decision coefficient; RPD, relative percent deviation. The same as below.

干季实测光谱基于 PCC 筛选光谱参量的 5 种模型建模效果较稳定， R_c^2 在 0.81~0.89 之间；基于 SR 筛选光谱参量的 5 种模型效果整体较好，且 GWR 模型效果优于其他 4 种全局模型。在全局模型下，SVM 和 BPNN 模型的 R_c^2 与 R_p^2 高于 PLSR 和 RR，PCC 组算法中，SVM 组的 R_p^2 和 RMSE 分别为 0.33 和 5.94，低于 BPNN 的 R_p^2 和 RMSE，而在 GC 和 SR 组算法中，SVM 组的 R_p^2 分别为 0.51 和 0.55，高于 SVM 模型，整体 BPNN 的 RMSE 平均为 3.96，为 3 个变量组中的最低值，预测能力最优。

在模型拟合度方面，以 GC 筛选光谱参量下的 GWR 模型效果最佳，其 R_c^2 与 R_p^2 分别为 0.91 和 0.94；在模型预测方面，以 SR 筛选光谱参量下的 GWR 模型效果最佳，其 RMSE 为 1.42，RPD 为 4.49，表明模型预测能力强。

干季影像模型建模效果较差，PCC 中光谱变量与含盐量均未通过显著性检验，因此 PCC 组未参与建模，其余 2 种筛选光谱参量方法下，5 种模型中均以 GWR 模型效果最好，其次为 SVM 和 BPNN 模型，且 BPNN 的 R_c^2 与 R_p^2 相对较稳定，呈现出较好的“鲁棒性”，而 PLSR

模型其 R_p^2/R_c^2 比值较大, 模型呈现出“欠拟合”的效果。对比分析 10 个模型精度发现, 基于 GC 筛选光谱参量下的 GWR 盐分反演模型效果最佳, 其 R_p^2 和 RPD 分别为 0.70 和 1.88。比较 5 种回归方法对模型精度效果的影响发现, 4 种机器学习算法模型相比 PLSR 模型精度明显提高。整体 GC 筛选光谱参量模型效果好于 SR 筛选光谱参量模型精度, 但干季影像模型整体 R_c^2 与 R_p^2 均相差较大, 这可能是由于土壤盐渍化发生机理的复杂性导致的。

表 7 为湿季土壤含盐量建模与验证结果。湿季实测和影像建模效果整体较好, 湿季实测建模 R_c^2 不小于 0.64, R_p^2 在 0.55 以上, 其 R_c^2 和 R_p^2 整体较接近, 说明模型反

演能力较稳定。全局回归模型下, 在 PCC 组构建的模型中, SVM 和 BPNN 模型 R_p^2 分别为 0.93 和 0.95, 二者的 RMSE 相差 0.57; 在 GC 和 SR 组中, SVM 模型的 R_c^2 和 R_p^2 均高于 BPNN 模型, 且 SVM 模型 RMSE 也低于 BPNN, PCC 组中, BPNN 模型效果优于 SVM, 而在 GC 和 SR 组中, SVM 模型效果优于 BPNN; 以 GC 筛选光谱参量下的 SVM 模型预测能力极强。SR 筛选光谱参量下的 RR 模型精度高于 PCC 以及 GC。整体以 SR 筛选光谱参量中模型精度最佳, GC 筛选光谱参量在 SVM 方面表现出一定优势; 局部回归模型下, 以 PCC 筛选光谱参量中 GWR 模型效果最佳。

表 7 湿季土壤含盐量反演模型
Table 7 Modeling of soil salt content in wet season

分析方法 Analytical methods	建模方法 Modeling methods	湿季实测 Measured in wet season				湿季影像 Image in wet season			
		R_c^2	R_p^2	RMSE/(g·kg ⁻¹)	RPD	R_c^2	R_p^2	RMSE/(g·kg ⁻¹)	RPD
相关性分 析 PCC	偏最小二乘 PLSR	0.70	0.63	5.62	1.64	0.37	0.28	6.44	1.44
	支持向量机 SVM	0.93	0.72	4.22	2.19	0.92	0.94	2.41	3.85
	岭回归 RR	0.71	0.60	8.33	1.11	0.52	0.49	6.61	1.40
	BP 神经网络 BPNN	0.95	0.76	4.79	1.93	0.89	0.78	1.65	5.63
	地理加权回归 GWR	0.93	0.80	4.16	2.22	0.93	0.96	1.92	4.83
灰度关联 法 GC	偏最小二乘 PLSR	0.66	0.67	5.35	1.73	0.44	0.27	7.94	1.17
	支持向量机 SVM	0.97	0.88	3.14	2.94	0.86	0.81	3.05	3.04
	岭回归 RR	0.64	0.55	6.22	1.48	0.40	0.54	2.56	3.63
	BP 神经网络 BPNN	0.86	0.78	4.05	2.28	0.49	0.40	2.99	3.10
	地理加权回归 GWR	0.91	0.76	4.57	2.02	0.45	0.29	7.81	1.19
逐步回归 法 SR	偏最小二乘 PLSR	0.81	0.63	5.59	1.65	0.72	0.53	6.43	1.44
	支持向量机 SVM	0.97	0.79	4.52	2.05	0.89	0.81	3.02	3.07
	岭回归 RR	0.84	0.64	5.54	1.67	0.74	0.46	6.82	1.36
	BP 神经网络 BPNN	0.90	0.68	5.58	1.65	0.88	0.87	2.09	4.42
	地理加权回归 GWR	0.84	0.76	4.58	2.02	0.77	0.87	3.41	2.72

在湿季影像反演模型中, 同一光谱数据作为模型输入变量下, 全局模型中, 在模型拟合方面, 以 SVM 模型效果最佳, 其 R_c^2 和 R_p^2 分别达到了 0.92、0.86、0.89 和 0.94、0.81 和 0.81, 没有出现“过拟合”或“欠拟合”现象。在模型预测方面, 以 BPNN 模型最佳, 其 RMSE 平均值为 2.24, 为 4 个模型中的最低值, PRD 平均值为 4.83, 预测能力极佳。4 种全局回归模型方法中, 反演精度最高的是基于 PCC 筛选光谱参量的 BPNN 模型, 其 R_p^2 和 RPD 分别为 0.78 和 5.63, 局部回归模型下以 PCC 筛选光谱参量分析下 GWR 模型效果最佳, 其 R_p^2 和 RPD 分别为 0.96 和 4.83。

2.5 干湿季土壤含盐量反演结果

结合土壤含盐量反演模型评价的 4 个指标 R_c^2 、 R_p^2 、RMSE 和 RPD, 对比评价 PCC、GC 和 SR 三种方法筛选光谱参量下, PLSR、SVM、RR、BPNN 和 GWR 的反演模型效果。较高 R^2 、RPD 值以及较低 RMSE 值即为土壤含盐量最佳反演模型。分析表 6 和表 7 可知, 干季实测和影像均以 GC-GWR 模型效果最优, 其 R_p^2 和 RPD 分别为 0.94、0.70 和 4.49、1.88, 说明 GC-GWR 模型共同适用于该地区干季的实测数据和影像数据建模; 湿季实测

以 GC-SVM 模型反演效果最佳, 其 R_p^2 和 RPD 分别为 0.88 和 2.94, 湿季影像则以 PCC-GWR 模型效果最佳, 其 R_p^2 和 RPD 分别为 0.96 和 4.83。

3 讨论

本研究对实测高光谱数据进行重采样, 使其与影像波段相匹配, 在一定程度上可提高和促进土壤定量遥感监测盐渍化精度, 并且可以实现不同传感器间的性能比较^[20]。遥感传感器对土壤含盐量的反演能力, 取决于传感器的光谱数据对含盐量的敏感程度^[39], 因此, 特征光谱数据的选择是建立稳健模型的关键步骤。本研究中 3 种方法筛选的特征变量数量存在较大差异, 18 个特征变量 (7 个波段和 11 个盐分指数) 中基于 PCC 的特征变量数除干季影像外, 均通过了显著性检验; 基于 GC 分析的干湿季实测和影像特征变量数各不同, 干季实测、影像和湿季实测特征变量数较多; SR 得到的特征变量数量变化较大 (3~9 个)。这 3 种方法从原理来说, GC 和 SR 的结果更为可靠, 当然, 不同的光谱变量筛选方法对于敏感光谱的筛选, 只可作为光谱寻优等研究的一种参考, 与模型反演效果之间的关系, 还需做更严谨的数学推理^[40]。

选择合适的模型输入变量和模型回归方法是提高土壤含盐量预测精度的有效途径。本研究发现基于 SR 分析筛选敏感光谱指数建立模型的稳定性和预测能力整体效果最优, 这与王海峰等^[10]的研究结果相同, 这是因为 SR 通过调整变量选择和排除的显著性水平, 实现对模型复杂度的优化构建, 但李明亮^[41]指出 GC 分析筛选敏感光谱指数建模优于线性相关性分析筛选建模, 这可能是由于研究对象在盐分含量、粗糙度和质地等方面存在一定差异造成的。有研究指出, 土壤成分对光谱模型的性能有很大的影响, 因此 GC 法的适用性有待商榷^[42]。对比 5 种模型建模效果, 发现全局模型中 SVM 和 BPNN 机器学习算法比传统建模方法 PLSR 在含盐量反演中的可靠性更高, 这与王飞等^[43]、张智韬等^[21]在对含盐量反演中, 机器学习模型的精度远高于传统模型的结论一致。但 BPNN 网络结构与节点设置均依靠经验, 易于陷入局部极值及出现“过拟合”^[44]。以往土壤含盐量的光谱反演研究主要采用 PLSR、MLR、BPNN 等全局回归模型, 这些模型中均未考虑到回归参数与空间位置的关系, 只考虑研究区的平均值, 而在实际研究过程中, 数据建模的回归参数是随着地理位置而变化的。GWR 作为一种局部多元回归方法, 在空间回归等方面有较好的效果^[45]。本文中 GWR 模型效果普遍较好于全局模型, 且干季模型效果好于湿季, 这是因为土壤盐分的空间变异性是盐渍土重要的自然属性之一^[19], 且干季含盐量空间变异性大于湿季, 空间变异程度越高, GWR 模型精度越高^[46], 但模型的实用性会受到一定限制^[47], 而 RR 作为一种新型的多元回归模型, 在遥感领域部分学者在尝试利用 RR 反演叶绿素浓度^[15]、叶面积指数^[48]、净初级生产力(Net Primary Productivity, NPP)^[34]和土壤含水率^[14]等方面都得到了较好的效果, 但是 RR 在含盐量方面的研究较少见到, 作为一种全局建模方法, 本文中 RR 含盐量反演模型也取得了较好的结果, 但是效果不及 SVM 和 BPNN 模型, 这可能是因为 RR 模型在 k 值选择上存在着一定的主观人为性, 且操作过程较为复杂, 所以降低了模型的简便性和稳定性。有研究指出 RR 作为一种有偏估计方法, 虽然放弃了最小二乘的无偏性、放弃部分精确度, 回归效果稍差, 但是其更符合实际的回归过程^[49]。需要指出的是, 土壤盐分组成复杂, 且呈现严重的区域性和空间变异性, 因此某一种算法在不同地区可能出现不同的效果, 因此在具体研究中应具体分析^[19,50]。

本文利用 5 种回归方法进行了土壤含盐量反演, 在后续的研究将进一步扩大样本数量, 利用长时间序列的实测和影像数据探讨干湿季对土壤含盐量影响, 以提高模型的普适性与准确性。

4 结 论

1) 研究区干湿两季土壤含盐量空间变异性均为强度变异, 干季变异性大于湿季。在不同土壤盐渍化条件下, 实测高光谱重采样波段与影像波段具有极显著相关性。

2) 基于相关性分析确定的干湿季实测和影像特征光谱数量最多, 但干季影像与含盐量相关性分析均未通过

显著性检验; 基于灰度关联法确定的土壤特征光谱湿季影像较少; 基于逐步回归方法确定的特征光谱数量差异较大。基于 3 种模型输入变量构建的含盐量反演模型, 逐步回归模型精度相对最高。

3) 对比干湿季基于实测和影像模型的盐分反演模型, 局部回归模型效果优于全局回归模型, 其中全局模型中以支持向量机和 BP 神经网络模型精度较高, 局部模型精度也因含盐量特征的不同而不同, 干季精度大于湿季。研究结果证实了局部回归模型在土壤含盐量反演方面的优越性。

4) 干季实测和影像均以灰度关联-地理加权回归模型反演效果最佳, 而湿季实测以灰度关联-支持向量机模型反演效果最佳; 湿季影像则以相关性分析-地理加权回归模型效果最佳。

[参 考 文 献]

- [1] Scudiero E, Skaggs T H, Corwin D L. Comparative regional-scale soil salinity assessment with near-ground apparent electrical conductivity and remote sensing canopy reflectance[J]. *Ecological Indicators*, 2016, 70: 276-284.
- [2] Whitney K, Scudiero E, Elaskary H M, et al. Validating the use of MODIS time series for salinity assessment over agricultural soils in California, USA[J]. *Ecological Indicators*, 2018, 93: 889-898.
- [3] 李建国, 濮励杰, 朱明, 等. 土壤盐渍化研究现状及未来研究热点[J]. *地理学报*, 2012, 67(9): 1233-1245.
Li Jianguo, Pu Lijie, Zhu Ming, et al. The present situation and hot issues in the salt-affected soil research[J]. *Acta Geographica Sinica*, 2012, 67(9): 1233-1245. (in Chinese with English abstract)
- [4] 黄帅, 丁建丽, 李相, 等. 土壤盐渍化高光谱特征分析与建模[J]. *土壤通报*, 2016, 47(5): 1042-1048.
Huang Shuai, Ding Jianli, Li Xiang, et al. Hyperspectral characteristics analysis and modeling of soil salinization[J]. *Chinese Journal of Soil Science*, 2016, 47(5): 1042-1048. (in Chinese with English abstract)
- [5] 陈仲新, 任建强, 唐华俊, 等. 农业遥感研究应用进展与展望[J]. *遥感学报*, 2016, 20(5): 748-767.
Chen Zhongxin, Ren Jianqiang, Tang Huajun, et al. Progress and perspectives on agricultural remote sensing research and applications in China[J]. *Journal of Remote Sensing*, 2016, 20(5): 748-767. (in Chinese with English abstract)
- [6] 史舟, 梁宗正, 杨媛媛, 等. 农业遥感研究现状与展望[J]. *农业机械学报*, 2015, 46(2): 247-260.
Shi Zhou, Liang Zongzheng, Yang Yuanyuan, et al. Status and prospect of agricultural remote sensing[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2015, 46(2): 247-260. (in Chinese with English abstract)
- [7] 王飞, 丁建丽, 魏阳, 等. 基于 Landsat 系列数据的盐分指数和植被指数对土壤盐度变异性的响应分析: 以新疆天山南北典型绿洲为例[J]. *生态学报*, 2017, 37(15): 5007-5022.
Wang Fei, Ding Jianli, Wei Yang, et al. Sensitivity analysis of soil salinity and vegetation indices to detect soil salinity variation by using Landsat series images: Applications in different oases in Xinjiang, China[J]. *Acta Ecologica Sinica*, 2017, 37(15): 5007-5022. (in Chinese with English abstract)

- [8] Farahmand N, Sadeghi V. Estimating soil salinity in the dried lake bed of Urmia Lake using optical Sentinel-2 images and nonlinear regression Models[J/OL]. Journal of the Indian Society Remote Sensing(2020). https://xs. Scihub. Itd/https://doi.org/10.1007/s12524-019-01100-8.
- [9] Wang Jingzhe, Ding Jianli, Yu Danlin, et al. Capability of Sentinel-2 MSI data for monitoring and mapping of soil salinity in dry and wet seasons in the Ebinur Lake region, Xinjiang, China[J]. Geoderma, 2019, 353: 172-187.
- [10] 王海峰. 基于高光谱遥感的土壤水盐监测模型研究[D]. 杨凌: 西北农林科技大学, 2019.
Wang Haifeng. Hyperspectral Remote Sensing Based Models for Soil Moisture and Salinity Prediction[D]. Yangling: Northwest A&F University, 2019. (in Chinese with English abstract)
- [11] 张俊华, 贾萍萍, 孙媛, 等. 基于高光谱特征的盐渍化土壤不同土层盐分离子含量预测[J]. 农业工程学报, 2019, 35(12): 106-115.
Zhang Junhua, Jia Pingping, Sun Yuan, et al. Prediction of salinity parameters in different saline soil layers based on hyperspectral data[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2019, 35(12): 106-115. (in Chinese with English abstract)
- [12] 冯娟, 丁建丽, 杨爱霞, 等. 土壤盐渍化信息遥感建模[J]. 干旱地区农业研究, 2018, 36(1): 266-273.
Feng Juan, Ding Jianli, Yang Aixia, et al. Remote sensing modeling of soil salinization information in arid areas[J]. Agricultural Research in the Arid Areas, 2018, 36(1): 266-273. (in Chinese with English abstract)
- [13] 刘恩, 王军涛, 常步辉, 等. 小开河引黄灌区土壤盐渍化定量遥感反演[J]. 中国农村水利水电, 2019(12): 20-24.
Liu En, Wang Juntao, Chang Buhui, et al. Quantitative remote sensing inversion of soil salinization in Xiaokaihe Yellow River irrigation district [J]. China Rural Water and Hydropower, 2019(12): 20-24. (in Chinese with English abstract)
- [14] 张智韬, 王海峰, Arnon Karnieli, 等. 基于岭回归的土壤含水率高光谱反演研究[J]. 农业机械学报, 2018, 49(5): 240-248.
Zhang Zhitao, Wang Haifeng, Arnon Karnieli, et al. Inversion of soil moisture content from hyperspectra based on ridge regression[J]. Transactions of the Chinese Society for Agricultural Machinery, 2018, 49(5): 240-248. (in Chinese with English abstract)
- [15] Verrelst J, Muñoz J, Alonso L, et al. Machine learning regression algorithms for biophysical parameter retrieval: Opportunities for Sentinel-2 and -3[J]. Remote Sensing of Environment, 2012, 118: 127-139.
- [16] 吴春生, 黄翀, 刘高焕, 等. 黄河三角洲土壤含盐量空间预测方法研究[J]. 资源科学, 2016, 38(4): 704-713.
Wu Chunsheng, Huang Chong, Liu Gaohuan, et al. Spatial prediction of soil salinity in the Yellow River Delta based on geographically weighted regression[J]. Resources Science, 2016, 38(4): 704-713. (in Chinese with English abstract)
- [17] Pelto C R, Elkins T A, Boyd H A. Automatic contouring of irregularly spaced data[J]. Geophysics, 1968, 33(3): 424-424.
- [18] Fotheringham A S, Charlton M, Brunsdon C. The geography of parameter space: An investigation of spatial non-stationarity[J]. International Journal of Geographical Information Systems, 1996, 10(5): 605-627.
- [19] Li H Y, Marchant B P, Webster R. Modelling the electrical conductivity of soil in the Yangtze delta in three dimensions[J]. Geoderma, 2016, 269: 119-125.
- [20] 阿尔达克·克里木, 塔西甫拉提·特依拜, 张东, 等. 基于高光谱的 ASTER 影像土壤盐分模型校正及验证[J]. 农业工程学报, 2016, 32(12): 144-150.
Ardak-Kelimu, Tashpolat-Tiyip, Zhang Dong, et al. Calibration and validation of soil salinity estimation model based on measured hyperspectral and ASTER image[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2016, 32(12): 144-150. (in Chinese with English abstract)
- [21] 张智韬, 魏广飞, 姚志华, 等. 基于无人机多光谱遥感的土壤含盐量反演模型研究[J]. 农业机械学报, 2019, 50(12): 151-160.
Zhang Zhitao, Wei Guangfei, Yao Zhihua, et al. Research on soil salt inversion model based on UAV multispectral remote sensing[J]. Transactions of the Chinese Society for Agricultural Machinery, 2019, 50(12): 151-160. (in Chinese with English abstract)
- [22] 贾萍萍, 孙媛, 尚天浩, 等. 基于高光谱和 Landsat-8 OLI 影像的盐渍化土壤水盐估算模型构建[J]. 生态学杂志, 2020, 39(7): 2456-2466.
Jia Pingping, Sun Yuan, Shang Tianhao, et al. Estimation models of soil water-salt based on hyperspectral and Landsat-8 OLI image[J]. Chinese Journal of Ecology, 2020, 39(7): 2456-2466. (in Chinese with English abstract)
- [23] 王遵亲, 祝寿全, 俞仁培, 等. 中国盐渍土[M]. 北京: 科学出版社, 1993.
- [24] Wang Xiaoping, Zhang Fei, Ding Jianli, et al. Estimation of soil salt content (SSC) in the Ebinur Lake Wetland National Nature Reserve (ELWNNR), Northwest China, based on a bootstrap-BP neural network model and optimal spectral indices[J]. Science of the Total Environment, 2018, 615, 918-930.
- [25] Allbed A, Kumer L, Aldakheel Y Y, et al. Assessing soil salinity using soil salinity and vegetation indices derived from IKONOS high-spatial resolution imageries: Applications in a date palm dominated region[J]. Geoderma, 2014, 230-231: 1-8.
- [26] Khan N M, Rastoskuev V V, Sato Y, et al. Assessment of hydrosaline land degradation by using a simple approach of remote sensing indicators[J]. Agricultural Water Management, 2005, 77(1): 96-109.
- [27] Douaoui A E K, Nicolas H, Walter C. Detecting salinity hazards within a semiarid context by means of combining soil and remote-sensing data[J]. Geoderma, 2006, 134(1): 217-230.
- [28] Abbas A, Khan S. Using remote sensing techniques for appraisal of irrigated soil salinity[C].//New Zealand: MODSIM 2007 International Congress on Modelling and Simulation, 2007.
- [29] 曹雷, 丁建丽, 玉米提·哈力克, 等. 基于国产高分一号卫星数据的区域土壤盐渍化信息提取与建模[J]. 土壤学报, 2016, 53(6): 1399-1409.
Cao Lei, Ding Jianli, Umut-Halik, et al. Extraction and modeling of regional soil salinization based on data from GF-1 satellite[J]. Acta Pedologica Sinica, 2016, 53(6): 1399-1409.

- 1399-1409. (in Chinese with English abstract)
- [30] Weng Yongling, Gong Peng, Zhu Zhiliang. Reflectance spectroscopy for the assessment of soil salt content in soils of the Yellow River Delta of China[J]. *International Journal of Remote Sensing*, 2008, 29(19): 5511-5531.
- [31] 刘思峰, 杨英杰, 吴利丰. 灰色系统理论及其应用[M]. 北京: 科学出版社, 2015.
- [32] Kennard R W, Stone L A. Computer aided design of experiments[J]. *Technometrics*, 1969, 11(1): 137-148.
- [33] 于雷, 洪永胜, 耿雷, 等. 基于偏最小二乘回归的土壤有机质含量高光谱估算[J]. *农业工程学报*, 2015, 31(14): 103-109.
- Yu Lei, Hong Yongsheng, Geng Lei, et al. Hyperspectral estimation of soil organic matter content based on partial least squares regression[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2015, 31(14): 103-109. (in Chinese with English abstract)
- [34] 焦伟, 陈亚宁, 李稚, 等. 基于多种回归分析方法的西北干旱区植被 NPP 遥感反演研究[J]. *资源科学*, 2017, 39(3): 545-556.
- Jiao Wei, Chen Yaning, Li Zhi, et al. Inversion of net primary productivity in the arid region of Northwest China based on various regressions[J]. *Resources Science*, 2017, 39(3): 545-556. (in Chinese with English abstract)
- [35] Xiao Zhenzhen, Li Yi, Feng Hao. Modeling soil cation concentration and sodium adsorption ratio using observed diffuse reflectance spectra[J]. *Canadian Journal of Soil Science*, 2016, 96(4): 372-385.
- [36] 唐启义. DPS 数据处理系统[M]. 北京: 科学出版社, 2010.
- [37] 于瀚辰, 沈体雁, 孙童. 中国 ICT 设备制造业的动态空间分异[J]. *地域研究与开发*, 2019, 38(1): 1-5.
- Yu Hanchen, Shen Tiyan, Sun Tong. Spatio-temporal heterogeneity of ICT equipment manufacturing industry in China[J]. *Area Research and Development*, 2019, 38(1): 1-5. (in Chinese with English abstract)
- [38] 李传华, 赵军, 师银芳, 等. 基于变异系数的植被 NPP 人为影响定量研究: 以石羊河流域为例[J]. *生态学报*, 2016, 36(13): 4034-4044.
- Li Chuanhua, Zhao Jun, Shi Yinfang, et al. The impact of human activities on net primary productivity based on the coefficient of variation: A case study of the Shiyang River Basin[J]. *Acta Ecologica Sinica*, 2016, 36(13): 4034-4044. (in Chinese with English abstract)
- [39] 夏军, 张飞. 热红外光谱的干旱区土壤含盐量遥感反演[J]. *光谱学与光谱分析*, 2019, 39(4): 1063-1069.
- Xia Jun, Zhang Fei. A study on remote sensing inversion of soil salt content in arid area based on thermal infrared spectrum[J]. *Spectroscopy and Spectral Analysis*, 2019, 39(4): 1063-1069. (in Chinese with English abstract)
- [40] 王海峰, 张智韬, Arnon Karnieli, 等. 基于灰度关联-岭回归的荒漠土壤有机质含量高光谱估算[J]. *农业工程学报*, 2018, 34(14): 124-131.
- Wang Haifeng, Zhang Zhitao, Arnon Karnieli, et al. Hyperspectral estimation of desert soil organic matter content based on gray correlation-ridge regression model[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2018, 34(14): 124-131. (in Chinese with English abstract)
- [41] 李明亮. 土壤有机质高光谱灰色关联度估测模型研究[D]. 泰安: 山东农业大学, 2017.
- Li Mingliang. Study on the Grey Relation Degree Estimation on Model of Soil Organic Matter Based on Hyperspectral[D]. Taian: Shandong Agricultural University, 2017. (in Chinese with English abstract)
- [42] Viscarra Rossel R A, Webster R. Predicting soil properties from the Australian soil visible-near infrared spectroscopic database[J]. *European Journal of Soil Science*, 2012, 63(6): 848-860.
- [43] 王飞, 杨胜天, 丁建丽, 等. 环境敏感变量优选及机器学习算法预测绿洲土壤盐分[J]. *农业工程学报*, 2018, 34(22): 102-110.
- Wang Fei, Yang Shengtian, Ding Jianli, et al. Environmental sensitive variable optimization and machine learning algorithm using in soil salt prediction at oasis[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2018, 34(22): 102-110. (in Chinese with English abstract)
- [44] 林宇锋, 邓洪敏, 史兴宇. 基于新的改进粒子群算法的 BP 神经网络在拟合非线性函数中的应用[J]. *计算机科学*, 2017, 44(S2): 51-54.
- Lin Yufeng, Deng Hongmin, Shi Xingyu. Application of BP neural network based on newly improved particle swarm optimization algorithm in fitting nonlinear function[J]. *Computer science*, 2017, 44(S2): 51-54. (in Chinese with English abstract)
- [45] 赵明松, 刘斌寅, 卢宏亮, 等. 基于地理加权回归的地形平缓区土壤有机质空间建模[J]. *农业工程学报*, 2019, 35(20): 102-110.
- Zhao Mingsong, Liu Binyin, Lu Hongliang, et al. Spatial modeling of soil organic matter over low relief areas based on geographically weighted regression[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2019, 35(20): 102-110. (in Chinese with English abstract)
- [46] 刘宁. 矿区耕地土壤重金属含量 GWR 模型反演研究[D]. 长沙: 长沙理工大学, 2018.
- Liu Ning. Inversion of Heavy Metals with GWR Model in Arable Land in Mining Area[D]. Changsha: Changsha University of Science & Technology, 2018. (in Chinese with English abstract)
- [47] 赵彦锋, 李豪杰, 陈杰, 等. 基于土壤变异解释力的几种土壤制图方法的对比研究: 以南阳市 1 m 土体土壤有机碳密度制图为例[J]. *土壤学报*, 2017, 55(1): 43-53.
- Zhao Yanfeng, Li Haojie, Chen Jie, et al. Comparison between soil mapping approaches based on their ability explaining soil variability: A case of mapping soil organic carbon density of soil(1m) in Nanyang district[J]. *Acta Pedologica Sinica*, 2017, 55(1): 43-53. (in Chinese with English abstract)
- [48] Caicedo J P R, Verrelst J, Munoz-Mari J, et al. Toward a semiautomatic machine learning retrieval of biophysical parameters[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2014, 7(4): 1249-1259.
- [49] 任媛媛, 姚宏亮. 岭回归视角下金融数据分析与算法实现[J].

经济研究导刊, 2013(32): 206-209.

Ren Yuanyuan, Yao Hongliang. Financial data analysis and algorithm realization from the perspective of the ridge regression[J]. Economic Research Guide, 2013(32): 206-209. (in Chinese with English abstract)

[50] 翁永玲, 宫鹏. 土壤盐渍化遥感应用研究进展[J]. 地理科学, 2006, 26(3): 369-375.

Weng Yongling, Gong Peng. A Review on remote sensing technique for salt-affected soils[J]. Scientia Geographica Sinica, 2006, 26(3): 369-375. (in Chinese with English abstract)

Inversion of soil salinity in dry and wet seasons based on multi-source spectral data in Yinbei area of Ningxia, China

Jia Pingping, Shang Tianhao, Zhang Junhua^{*}, Sun Yuan

(1. College of Resources and Environmental Science, Ningxia University, Yinchuan 750021, China; 2. Institute of Environmental Engineering, Ningxia University, Yinchuan 750021, China; 3. Ningxia Key Laboratory of Resource Assessment and Environment Regulation in Arid Region, Yinchuan 750021, China)

Abstract: Soil salinization is one of the main causes of global desertification and soil degradation. Information data about salinity and alkalinity is essential to the treatment of alkalinized soil for preventing its further degradation and sustainable development of agriculture. Soil salinization is often characterized with significant spatiotemporal dynamics. Taking the saline soil in Pingluo County as the research object, which is predominant in the Ningxia Yinbei area of Northwestern China, this study aims to explore the salt content of soil in dry and wet seasons, and then compare the accuracy of local models and global models, further to determine the optimal model for retrieving soil salinity using the hyperspectral and multispectral remote sensing. The specific processing is following, based on hyperspectral and Landsat 8 OLI image data in the dry season (April) and wet season (October). First, the hyperspectral data was resampled to the image band range for matching the two, whereas, the 11 salt indices under the two spectral data were calculated separately. Second, different algorithms including pearson correlation coefficient (PCC), stepwise regression (SR) and gray relational analysis (GRA) were applied for the sensitive band and index screening of the measured and image spectral data in the dry and wet seasons. Finally, the quantitative analysis models for soil salinity were established using the partial least squares regression (PLSR), support vector machine (SVM), ridge regression (RR), BP neural networks (BPNN), and geographically weighted regression (GWR) method, respectively. All these regression models were verified to select the optimal model, after comparing the effects of different input variables and different regression methods on the model precision. The results showed that: 1) The soil of the Yinbei region was strongly salt-affected, and the salt content in the wet and dry season was characterized by the intensity variation, where the variation degree of dry season was much higher than that of the wet season. 2) The resampling bands showed a good correlation with the image bands data under different soil salinity. 3) The SR group model achieved the best inversion effect, whereas, the PC and GC groups indicated advantages and disadvantages in different regression algorithms, after comparing of the R^2 , RMSE and RPD of the salt salinity inversion model under the three filter variables of PCC, GC and SR. 4) In the five inversion models of soil salinity, the GWR model showed a higher accuracy. The SVM and BPNN algorithm performed similarly in the models, based on different variable groups, whereas, the RR performance was the worst, particularly a serious “overfitting” phenomenon in the PLSR model. The evaluation results demonstrated the superiority of the local regression over the global regression model for soil salinity. The measured GC-GWR model in dry season achieved the best inversion effect, where the values of R_p^2 and RPD were 0.94 and 4.49, in the wet season, whereas, the imaged PCC-GWR model obtained the best inversion effect, where the values of R_p^2 and RPD were 0.96 and 4.83. These findings can contribute to tackling the regional land salinization and degradation, as well as identification and prevention of soil salinization in local and similar areas, further to soil salinization monitoring and land reclamation in arid or semi-arid regions outside the current study area.

Keywords: remote sensing; inversion; models; soil salt; spectral index; GWR model